



ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

DIPARTIMENTO DI INFORMATICA - SCIENZA E INGEGNERIA
Corso di Laurea Triennale in Ingegneria e scienze informatiche

Intelligent Reflecting Surfaces

Progettazione, modellazione e ottimizzazione

Tesi di Laurea in Machine Learning e Telecomunicazioni

Relatore:
Chiar.mo Prof.
Andrea Piroddi

Presentata da:
Alessandro Rebosio

Sessione I
Anno Accademico 2025/2026

Qui ci va la dedica/citazione

Introduzione

Negli ultimi anni l'evoluzione delle reti di comunicazione wireless ha conosciuto una crescita rapida e diffusa, alimentata dalla domanda di connettività ad alta velocità, da requisiti di bassa latenza e dal consistente aumento del numero di dispositivi connessi. Le reti di quinta generazione (5G) hanno rappresentato un salto qualitativo significativo, contribuendo al raggiungimento di ambiziosi obiettivi di capacità almeno mille volte superiore alle tecnologie precedenti e connettività ubiqua per decine di miliardi di dispositivi. Questo risultato è stato reso possibile grazie all'impiego di soluzioni tecnologiche avanzate, quali il Multiple-Input Multiple-Output Massivo (Massive MIMO), le comunicazioni in banda millimetrica (mmWave) e le reti ultra-dense (Ultra Dense Networks, UDN).

Nonostante i significativi benefici apportati, le reti 5G continuano a presentare criticità rilevanti legate alla complessità hardware, ai costi di implementazione e al consumo energetico. In particolare, l'estensione del Massive MIMO dalle bande sub-6 GHz alle frequenze millimetriche richiede architetture altamente complesse, un maggior numero di catene a radiofrequenza (RF) e hardware sofisticato e costoso dal punto di vista energetico. Parallelamente, la propagazione in banda mmWave risulta fortemente penalizzata dalla vulnerabilità al blocco indoor e dai fenomeni di attenuazione, rendendo difficile mantenere livelli affidabili di copertura e qualità del segnale.

In questo contesto, il paradigma tradizionale di adattamento basato esclusivamente sulla progettazione del trasmettitore e del ricevitore mostra limitazioni crescenti, motivando un ripensamento radicale dell'ambiente di propagazione. Le Intelligent Reflecting Surfaces (IRS) emergono come una tecnologia promettente per riconfigurare in modo intelligente l'ambiente di propagazione mediante il controllo di elementi riflettenti passivi a basso costo. Questo approccio introduce un nuovo grado di libertà nella gestione del

canale radio, permettendo di migliorare copertura, efficienza spettrale ed energetica e di mitigare fenomeni di fading e di interferenza con costi di implementazione contenuti rispetto alle soluzioni tradizionali.

L'integrazione delle IRS in sistemi Massive MIMO e in scenari 5G e oltre-5G comporta tuttavia sfide tecniche significative e ancora largamente inesplorate. Queste includono la modellazione accurata del canale in presenza di superfici riflettenti passive, la progettazione congiunta dei beamforming attivi e passivi, l'acquisizione affidabile della CSI negli scenari multiutente e dinamici, e la gestione della complessità computazionale intrinseca in tali sistemi ibridi. Molti problemi di ottimizzazione nei sistemi assistiti da IRS sono non convessi, perché la funzione obiettivo dipende da prodotti tra variabili (ad esempio tra coefficienti di canale e fasi dell'IRS) e può quindi presentare molti massimi e minimi locali. In questi casi, gli approcci analitici classici spesso non garantiscono il raggiungimento della soluzione globale e diventano poco efficaci quando il sistema deve essere riconfigurato rapidamente al variare delle condizioni di propagazione.

In questa prospettiva, le tecniche di Machine Learning rappresentano strumenti potenti e versatili per affrontare la complessità dimensionale e la non-linearità di reti assistite da IRS. In particolare, possono supportare l'ottimizzazione adattiva dei coefficienti di riflessione e, più in generale, il controllo della superficie sulla base di indicatori di prestazione osservati.

L'obiettivo principale di questa tesi è proporre e valutare un quadro metodologico per l'analisi delle reti wireless assistite da IRS mediante tecniche di Machine Learning, con particolare attenzione alla modellazione del problema, agli algoritmi di apprendimento, e alla validazione mediante simulazioni. In particolare, il lavoro si concentra sul controllo dinamico delle IRS in scenari indoor, evidenziando modello, metriche e metodologia sperimentale.

Indice

Introduzione	ii
1 Contesto, motivazione e obiettivi	1
1.1 Problemi di copertura indoor nelle reti wireless	1
1.2 Limiti delle soluzioni tradizionali	2
1.3 Intelligent Reflecting Surfaces: idea di base	2
1.4 Obiettivi e contributi della tesi	3
2 Fondamenti teorici	4
2.1 Propagazione radio in ambiente indoor	4
2.2 Principio di funzionamento delle IRS	5
2.2.1 Motivazione per approcci basati su Machine Learning	6
2.3 Modello di canale assistito da IRS	7
2.3.1 Modellazione dei canali	7
2.3.2 Problema di ottimizzazione	8
3 Scenario di riferimento	9
3.1 Descrizione dello scenario	9
3.2 Assunzioni del modello	11
3.3 Modello di canale specifico	12
3.4 Metriche di valutazione	13
3.5 Formulazione RL per il controllo delle fasi IRS	14
4 Formulazione del problema di controllo	16
4.1 Ingresso al sistema di Machine Learning	17
4.1.1 Posizione utente	17
4.1.2 CSI semplificato	17
4.2 Vincoli pratici	18
4.3 Output: configurazione di fase IRS	19

5	Algoritmi di Machine Learning	20
5.1	Regressione multivariata	20
5.2	k-Nearest Neighbors	22
5.3	Multi-Layer Perceptron (MLP)	23
5.4	Confronto tra modelli	24
5.4.1	Accuratezza	24
5.4.2	Complessità	25
5.4.3	Stabilità	26
6	Processo di addestramento	27
6.1	Generazione dataset sintetico	27
6.2	Suddivisione training e test	28
6.3	Flusso sperimentale	28
6.4	Metriche di apprendimento	29
6.5	Overfitting e generalizzazione	30
7	Risultati sperimentali	31
7.1	Confronto prestazionale dei modelli	31
7.1.1	Analisi delle metriche principali	32
7.2	Sensibilità alla quantizzazione	33
7.2.1	Andamento del Tracking@1 con K	34
7.3	Distribuzione errore e analisi spaziale	35
7.4	Discussione	36
8	Conclusioni e sviluppi futuri	37
8.1	Risultati principali	37
8.2	Contributi metodologici	37
8.3	Limiti del lavoro	38
8.4	Sviluppi futuri	38
8.5	Considerazioni finali	39

Capitolo 1

Contesto, motivazione e obiettivi

1.1 Problemi di copertura indoor nelle reti wireless

Negli ambienti indoor la copertura radio presenta sfide significative rispetto agli scenari outdoor a causa della complessità geometrica e dei materiali costruttivi. Le onde elettromagnetiche incontrano pareti, pavimenti, soffitti, mobili e altre superfici che causano attenuazione di penetrazione (penetration loss) variabile con la frequenza e con la tipologia di materiale; materiali come calcestruzzo, vetro stratificato o metallo possono introdurre perdite elevate e creare "zone d'ombra" attorno a sorgenti di segnale.

Un altro fenomeno critico è il multipath: il segnale trasmesso arriva al ricevitore attraverso molteplici percorsi dovuti a riflessioni, diffrazioni e scattering. Questa ricombinazione di contributi può generare fenomeni di fading su piccola scala, variazioni rapide dell'ampiezza e della fase del segnale, e allungamento temporale dell'impulso (delay spread) che peggiora la qualità del collegamento e aumenta la probabilità di errori nella ricezione.

La dipendenza dalla frequenza è particolarmente rilevante nelle bande mmWave: sebbene tali frequenze forniscano ampia larghezza di banda e alte capacità, presentano elevata attenuazione in presenza di ostacoli e sono fortemente sensibili al blocco da parte di elementi mobili (persone, porte) e fissi (mobili metallici). Questo rende la copertura mmWave in ambienti indoor del tutto multiforme e suscettibile a interruzioni frequenti.

La mobilità degli utenti e la presenza di ostacoli dinamici introducono ulteriori difficoltà: link temporaneamente Non in Linea di Vista (NLoS) possono degradare drasti-

camente le prestazioni, richiedendo procedure di riconvergenza, ri-allineamento dei fasci (beam alignment) o handover verso altre celle o punti di accesso.

Queste problematiche motivano l'adozione di approcci che agiscono direttamente sull'ambiente di propagazione, anziché limitarsi a ottimizzare esclusivamente trasmettitore e ricevitore. Le Intelligent Reflecting Surfaces (IRS) si inseriscono in questo contesto come possibile soluzione per riconfigurare il campo elettromagnetico in modo passivo e a basso costo, migliorando copertura e affidabilità in ambienti indoor complessi. [7]

1.2 Limiti delle soluzioni tradizionali

Le soluzioni tradizionali per il miglioramento della copertura presentano vincoli significativi. L'aumento della potenza trasmessa è limitato da normative sulla sicurezza elettromagnetica e da considerazioni di efficienza energetica; la densificazione della rete comporta costi infrastrutturali elevati, maggiore complessità gestionale e rischi di interferenza inter-cella. Le architetture Massive MIMO, sebbene promettenti per il guadagno di beamforming, richiedono numerose catene a Radio Frequenza (RF) e introducono oneri computazionali e di segnalazione significativi per l'acquisizione affidabile dell'Informazione sullo Stato del Canale (Channel State Information, CSI), specialmente nelle bande millimetriche dove la vulnerabilità al blocco e l'attenuazione sono critiche [1, 6, 7].

Un limite strutturale comune a queste soluzioni è la concentrazione esclusiva sull'ottimizzazione del trasmettitore e del ricevitore, trascurando il ruolo dell'ambiente di propagazione. Laddove geometrie complesse, materiali costruttivi e ostacoli generano effetti di riflessione, diffrazione e scattering difficili da controllare (scenario tipico degli ambienti indoor), i metodi convenzionali mostrano margini di miglioramento limitati, poiché operano su gradi di libertà poco influenti rispetto al canale effettivo percepito dall'utente.

1.3 Intelligent Reflecting Surfaces: idea di base

Le Intelligent Reflecting Surfaces (IRS) propongono un paradigma diverso rispetto alle soluzioni tradizionali: invece di limitarsi a ottimizzare i nodi trasmissivi, si modifica attivamente l'ambiente di propagazione mediante superfici passive composte da un elevato numero di elementi elementari riconfigurabili. Ogni elemento può introdurre uno

sfasamento (e, in alcune implementazioni, variazioni di ampiezza) al segnale incidente, permettendo di realizzare un beamforming passivo che ridistribuisce energia verso regioni d'interesse senza richiedere catene RF attive per ogni elemento [2, 11].

Dal punto di vista del controllo, il nucleo del problema è la scelta dei coefficienti di riflessione per gli elementi IRS in modo da massimizzare metriche quali potenza ricevuta, Rapporto Segnale-Rumore (Signal-to-Noise Ratio, SNR) o probabilità di copertura. La modellazione del canale in presenza di IRS introduce termini moltiplicativi che accrescono la non-convessità dei problemi di ottimizzazione e la complessità computazionale delle soluzioni classiche. Per questi motivi, le soluzioni basate su metodi euristici, ottimizzazione alternata e tecniche data-driven sono state proposte nella letteratura recente.

1.4 Obiettivi e contributi della tesi

Lo scopo di questo lavoro è sviluppare e valutare un metodo di controllo delle fasi basato su tecniche di Machine Learning per Intelligent Reflecting Surfaces (IRS) in scenari indoor. Il lavoro prevede la simulazione di un ambiente interno realistico e l'uso di algoritmi di apprendimento automatico (semplici e interpretabili) per stimare, a partire dalla posizione dell'utente, la configurazione di fase degli elementi IRS che massimizza la copertura e la potenza ricevuta. L'obiettivo finale è quantificare il guadagno di copertura e la robustezza ottenibili grazie all'IRS rispetto a configurazioni senza IRS o non ottimizzate, analizzando prestazioni in scenari multiutente e con canali tipici di bande mmWave. In sintesi, i contributi principali consistono nella definizione del modello di sistema, nella formulazione del problema di controllo e nella valutazione comparativa delle prestazioni.

Capitolo 2

Fondamenti teorici

2.1 Propagazione radio in ambiente indoor

Per modellare la propagazione radio indoor si adotta il modello di *basic transmission loss* raccomandato dall'International Telecommunication Union - Radiocommunication Sector (ITU-R) P.1238 [7] per collegamenti base station-utente all'interno dello stesso edificio. In particolare, per scenari in cui trasmettitore e ricevitore si trovano sullo stesso piano, la perdita di percorso mediana è espressa come:

$$L_b(\mathbf{d}, \mathbf{f}) = \mathbf{A} + 10 \mathbf{n} \log_{10}(\mathbf{d}) + \mathbf{B} \log_{10}(\mathbf{f}) + \mathbf{X}_\sigma \quad [\text{dB}] \quad (2.1)$$

dove $\mathbf{d}$ è la distanza tridimensionale tra trasmettitore e ricevitore (in metri), $\mathbf{f}$ la frequenza operativa (in GHz), $\mathbf{n}$ l'esponente di perdita di percorso, $\mathbf{A}$ e $\mathbf{B}$ coefficienti che modellano rispettivamente l'offset e la dipendenza dalla frequenza, mentre $\mathbf{X}_\sigma$ è una variabile aleatoria gaussiana a media nulla e deviazione standard σ che rappresenta lo **shadow fading** log-normale. I valori di $\mathbf{A}$, $\mathbf{n}$, $\mathbf{B}$ e σ sono forniti da ITU-R P.1238 per diversi ambienti (ufficio, corridoio, industriale, sala conferenze) e per condizioni In Linea di Vista (Line of Sight, LoS)/NLoS; nel presente lavoro si adotta la configurazione “office NLoS” nel range di distanza e frequenza coerente con le simulazioni assistite da IRS.

Oltre alla perdita di percorso media, l'ambiente indoor è caratterizzato da **multi-path** dovuto a riflessioni, diffrazioni e scattering su pareti, soffitti, pavimenti e arredo, che genera variazioni rapide di ampiezza e fase del segnale e un allungamento temporale dell'impulso. La risposta impulsiva del canale può essere descritta tramite il **power**

delay profile, da cui si ricava il **delay spread a media quadratica (root mean square, r.m.s.)** τ_{rms} , che per ambienti d'ufficio tipici assume valori mediani compresi tra alcune decine e alcune centinaia di nanosecondi, con variazioni dipendenti da frequenza, dimensioni del locale e larghezza di banda angolare delle antenne. In linea con i dati riportati in ITU-R P.1238, per il caso di ufficio indoor si considera un delay spread r.m.s. dell'ordine di **50–150 ns** (valori di Tabella 7 per ambienti “office” nelle bande GHz di interesse) e una deviazione standard dello shadow fading di circa 3–6 dB, a seconda della specifica combinazione ambiente/frequenza.

2.2 Principio di funzionamento delle IRS

Le *Intelligent Reflecting Surfaces* (IRS) sono metasuperfici planari con M elementi riconfigurabili (unit cells), spesso disposti su una griglia $N \times N$ con $M = N^2$ [2]. Ogni elemento modifica in modo controllato il segnale incidente; a differenza di una superficie riflettente passiva tradizionale, il comportamento elettromagnetico si può regolare in tempo reale tramite componenti come diodi PIN o varattori, senza catene RF attive per elemento.

Il comportamento dell'elemento $m = 1, \dots, M$ si descrive con il coefficiente di riflessione complesso:

$$\Gamma_m = \beta_m e^{j\theta_m}, \quad (2.2)$$

dove $\theta_m \in [0, 2\pi)$ è la fase controllabile e $\beta_m \in [0, 1]$ rappresenta l'attenuazione dovuta a perdite di inserzione ($\beta_m \approx 0.9$ –1 per implementazioni state-of-the-art).

Il principio fisico è il *beamforming passivo*: scegliendo le fasi $\{\theta_m\}_{m=1}^M$ in modo coerente, i contributi riflessi si sommano verso una direzione o una posizione obiettivo, aumentando il campo ricevuto nel regime far-field con un guadagno che cresce con M . Questo crea un cammino Stazione Base (Base Station, BS)–IRS–Equipaggiamento Utente (User Equipment, UE) controllabile, utile quando il collegamento diretto è indebolito da ostacoli indoor.

Nella pratica entrano tre vincoli: la quantizzazione della fase, perché θ_m assume pochi livelli discreti (es. 2–3 bit, $K = 4$ –8 livelli) per semplificare l'hardware [2]; l'overhead di configurazione, dato che le fasi sono impostate dal controller IRS (via backhaul dalla BS)

con latenza dell'ordine dei ms; e la dipendenza dalla posizione, per cui la configurazione ottima $\Theta^* = \arg \max_{\Theta} P_r(\mathbf{p})$ varia con la posizione utente $\mathbf{p}$.




Figura 2.1: Schema di funzionamento di una Intelligent Reflecting Surface (IRS): segnale incidente dalla BS, riconfigurazione di fase sugli elementi e beamforming verso l'UE. Immagine generata con ChatGPT [8] e rielaborata dall'autore.

2.2.1 Motivazione per approcci basati su Machine Learning

Il problema di ottimizzazione delle fasi IRS per massimizzare la potenza ricevuta $P_r(\mathbf{p})$ o metriche correlate (SNR, copertura) presenta sfide computazionali significative. La struttura moltiplicativa del canale assistito da IRS, discussa in sezione 2.3, introduce termini non-convessi che rendono inadeguati metodi di ottimizzazione locale classici, i quali possono convergere a minimi locali subottimali. Tecniche come l'ottimizzazione alternata o i metodi di rilassamento semidefinito (Semidefinite Relaxation, SDR) forniscono soluzioni approssimate ma richiedono tempi di calcolo proibitivi per sistemi con elevato numero di elementi ($M \gg 100$) e aggiornamenti frequenti.

Inoltre, la dipendenza dalla posizione $\mathbf{p}$ implica che la matrice di configurazione ottima $\Theta^*(\mathbf{p})$ deve essere ricalcolata continuamente al variare della posizione utente, rendendo impraticabile l'uso di ottimizzazione iterativa in scenari dinamici o con mobilità.

elevata. Per questi motivi, approcci *data-driven* basati su Machine Learning rappresentano una alternativa promettente: un modello addestrato su dataset di coppie $(\mathbf{p}, \Theta^*)$ generati tramite simulazioni di canali indoor realistici può apprendere la mappatura $\mathbf{p} \mapsto \{\theta_m\}$ in modo efficiente, fornendo previsioni in tempo reale con complessità computazionale ridotta rispetto a metodi iterativi. Nel presente lavoro si esplorano algoritmi semplici e interpretabili (regressione, alberi decisionali, reti neurali compatte) per stimare la configurazione di fase ottimale a partire dalle coordinate (x, y) dell'utente, valutando il guadagno di copertura ottenuto in ambienti indoor caratterizzati da propagazione multipath e blocco.

2.3 Modello di canale assistito da IRS

In uno scenario assistito da IRS, il collegamento BS–UE è mediato da una superficie riflettente riconfigurabile. Assumendo una potenza di trasmissione P_t e attenuazione di percorso sulle due tratte BS→IRS e IRS→UE, si adotta un modello cascaded a due hop, coerente con [4].

Sia $\mathbf{h}_{\text{BI}} \in \mathbb{C}^M$ il vettore di canale tra BS e i M elementi IRS, e sia $\mathbf{h}_{\text{IU}} \in \mathbb{C}^M$ il vettore di canale tra IRS e UE. Il canale efficace BS→IRS→UE è:

$$h_{\text{eff}} = \mathbf{h}_{\text{IU}}^H \text{diag}(\mathbf{\Gamma}) \mathbf{h}_{\text{BI}}, \quad (2.3)$$

dove $\mathbf{\Gamma} = [\Gamma_1, \dots, \Gamma_M]^T$ è il vettore dei coefficienti di riflessione definiti in (2.2), e $\text{diag}(\mathbf{\Gamma})$ è la matrice diagonale con Γ_m sulla diagonale (cfr. il modello $\mathbf{H}_{I,k} = \mathbf{G}^T \text{diag}(\mathbf{h}_{r,k})$ in [4]).

Assumendo, per semplicità, riflessione ideale senza perdite ($\beta_m = 1, \forall m$), si ottiene $\mathbf{\Gamma} = e^{j\boldsymbol{\theta}}$, con $\boldsymbol{\theta} = [\theta_1, \dots, \theta_M]^T$.

2.3.1 Modellazione dei canali

Per modellare i vettori di canale $\mathbf{h}_{\text{BI}}$ e $\mathbf{h}_{\text{IU}}$, si adotta un modello geometrico semplificato, coerente con la propagazione indoor descritta in sezione 2.1 e con scenari sub-6 GHz non sparsi [4]. In particolare, ciascun coefficiente $h_{\text{BI},m}$ e $h_{\text{IU},m}$ include:

- **Path loss:** calcolato tramite (2.1) in funzione delle distanze $d_{\text{BI},m}$ (BS $\rightarrow$ elemento m) e $d_{\text{IU},m}$ (elemento $m \rightarrow$ UE), con parametri dipendenti dall'ambiente [7];
- **Shadow fading:** termine log-normale modellato mediante variabile gaussiana X_σ con deviazione standard tipica 3–6 dB;
- **Small-scale fading:** fase casuale uniforme in $[0, 2\pi)$ per rappresentare gli effetti di multipath in regime narrowband (o su singola sottoportante OFDM).

Questo modello cattura sia la geometria dello scenario sia la dipendenza dei percorsi riflessi dalla posizione utente $\mathbf{p}$.

La potenza ricevuta tramite IRS è quindi:

$$P_r(\mathbf{p}, \boldsymbol{\theta}) = P_t |h_{\text{eff}}(\mathbf{p}, \boldsymbol{\theta})|^2. \quad (2.4)$$

2.3.2 Problema di ottimizzazione

Il problema di ottimizzazione consiste nel determinare $\boldsymbol{\theta}^*(\mathbf{p})$ che massimizza (2.4):

$$\boldsymbol{\theta}^*(\mathbf{p}) = \arg \max_{\boldsymbol{\theta} \in [0, 2\pi)^M} P_r(\mathbf{p}, \boldsymbol{\theta}), \quad (2.5)$$

soggetto ai vincoli di quantizzazione (fasi discrete a K livelli) e ai limiti hardware. La non-convessità di (2.5) e la dimensionalità elevata (M variabili) rendono questo problema computazionalmente complesso, motivando l'adozione di approcci data-driven (cfr. ottimizzazioni per phase shifting in [4]).

Inoltre, in scenari realistici è possibile che esista anche un collegamento diretto BS $\rightarrow$ UE; in tal caso la potenza totale ricevuta è:

$$P_r^{\text{tot}}(\mathbf{p}, \boldsymbol{\theta}) = P_t |h_{\text{direct}}(\mathbf{p}) + h_{\text{eff}}(\mathbf{p}, \boldsymbol{\theta})|^2, \quad (2.6)$$

dove $h_{\text{direct}}(\mathbf{p})$ è il canale diretto con path loss e fading propri, come nel modello con $h_{d,k}$ di [4]. Nelle simulazioni si considereranno entrambi i casi (con e senza link diretto) per valutare l'impatto dell'IRS in scenari di blocco completo (NLoS severo) e parziale.

Capitolo 3

Scenario di riferimento

3.1 Descrizione dello scenario

Lo scenario analizzato fa riferimento a un ambiente *indoor* di tipo *office NLoS* (Non Line-of-Sight), come definito nell'raccomandazione ITU-R P.1238 [7]. L'ambiente è modellato come una stanza rettangolare di dimensioni pari a $10\text{ m} \times 8\text{ m} \times 3\text{ m}$.

La *Base Station* (BS) è installata in prossimità di un angolo del soffitto, nel punto $(0, 0, 2.8)\text{ m}$, in accordo con una tipica configurazione per copertura *in-building*. Un *Intelligent Reflecting Surface* (IRS), costituito da $M = 64$ elementi disposti in una griglia 8×8 , è montato su una parete laterale nel punto $(9, 4, 1.5)\text{ m}$ e orientato verso l'interno della stanza, in modo da massimizzare la riflessione dei percorsi utili verso l'utente. La scelta di $M = 64$ rappresenta un compromesso tra guadagno di beamforming passivo e complessità: un numero di elementi inferiore riduce il margine di miglioramento della copertura, mentre valori più elevati aumentano la dimensionalità del problema ed il costo computazionale.

L'utente mobile (UE) si muove su un piano orizzontale a quota $z = 1\text{ m}$, con posizione $\mathbf{p} = (x, y, 1)$ distribuita uniformemente nell'area $[1, 8] \times [1, 7]\text{ m}$. Tale regione è stata definita escludendo le zone di copertura diretta più intensa, così da enfatizzare le condizioni NLoS e valutare l'efficacia del contributo riflesso mediato dall'IRS.

Il layout descritto rappresenta una configurazione tipica di scenario indoor NLoS, caratterizzata dalla presenza di ostacoli (ad esempio pareti o arredi interni) che possono attenuare o bloccare il collegamento diretto BS-UE. In tali condizioni, l'IRS assume un




Figura 3.1: Geometria dello scenario indoor: vista 3D con BS (blu), IRS (verde) e area di movimento dell'UE (arancione).

ruolo chiave nel ridirezionare il segnale e migliorare la qualità complessiva della copertura radio.

3.2 Assunzioni del modello

Per rendere il problema trattabile e isolare l'effetto del controllo di fase IRS, si adottano le seguenti assunzioni.

Dinamica del canale e localizzazione Si assume che il canale sia quasi-statico, ossia costante all'interno di un frame di durata $T_f = 10$ ms. Il controller IRS non dispone di CSI perfetta completa, bensì utilizza la posizione UE $\mathbf{p}$ stimata tramite localizzazione indoor con accuratezza media pari a 0.5 m. Durante un singolo frame la posizione dell'utente è considerata fissa; tra frame successivi $\mathbf{p}$ varia, generando così i campioni del dataset di training e test.

Configurazione hardware dell'IRS Si assume che l'IRS sia continuamente operativa con tutti gli elementi che operano a modulo unitario ($\beta_m = 1, \forall m$), senza modalità off-state o guasti parziali. Questa ipotesi rappresenta una configurazione idealizzata; in scenari realistici è possibile includere perdite di inserzione mediante $\beta_m \approx 0.9\text{--}0.95$.

Comunicazione e controllo L'overhead di controllo è trascurato, pertanto latenza e segnalazione sul collegamento BS–IRS (backhaul dedicato) non sono modellate esplicitamente. Si assume che il tempo di riconfigurazione degli elementi IRS sia trascurabile rispetto a T_f .

Modello di rumore Per il rumore termico si assume una densità spettrale di potenza $N_0 = -174$ dBm/Hz con larghezza di banda di interesse $B = 20$ MHz, da cui la potenza di rumore integrata è

$$N = N_0 + 10 \log_{10}(B) \approx -101 \text{ dBm}. \quad (3.1)$$

Non si include fattore di rumore addizionale (figura di rumore unitaria), ipotizzando ricevitori con amplificazione a basso rumore.

Validità delle assunzioni Queste ipotesi semplificative permettono di focalizzare l'analisi sul contributo del beamforming passivo IRS e sul confronto tra strategie di controllo differenti, isolando gli effetti del controllo di fase dai fenomeni secondari.

3.3 Modello di canale specifico

In questa sezione si considera uno scenario a utente singolo (single-user), in banda stretta (narrowband), alla frequenza $f = 3.5$ GHz (banda sub-6 GHz). Tale scelta è coerente con le ipotesi di propagazione indoor introdotte in sezione 2.1.

Il canale cascaded BS–IRS–UE segue la formulazione presentata nella sezione 2.3 (equazioni (2.3)–(2.4)). In particolare, $\mathbf{h}_{\text{BI}} \in \mathbb{C}^M$ indica il vettore di canale BS–IRS, mentre $\mathbf{h}_{\text{IU}}(\mathbf{p}) \in \mathbb{C}^M$ indica il vettore IRS–UE dipendente dalla posizione utente $\mathbf{p}$. Il vettore di fase IRS è $\boldsymbol{\theta} = [\theta_1, \dots, \theta_M]^T$, con quantizzazione a $K = 4$ livelli (2 bit per elemento):

$$\theta_m \in \left\{ 0, \frac{2\pi}{K}, \dots, \frac{2\pi(K-1)}{K} \right\}. \quad (3.2)$$

La scelta di $K = 4$ è coerente con vincoli hardware realistici e con la necessità di limitare l'overhead di controllo: 2 bit per elemento offrono una granularità di fase adeguata mantenendo contenuti complessità e latenza di riconfigurazione.

La potenza ricevuta totale è descritta da (2.6). Nel nostro scenario, il primo termine rappresenta il collegamento diretto attenuato secondo ITU-R P.1238 (office NLoS). Il modello incorpora:

- **Path loss:** calcolato tramite (2.1) in funzione delle distanze BS–elemento IRS e elemento IRS–UE;
- **Shadow fading log-normale:** con deviazione standard $\sigma = 4$ dB, valore tipico per ambienti d'ufficio indoor;
- **Small-scale fading:** fase aleatoria uniforme in $[0, 2\pi)$ per simulare fenomeni di multipath in regime narrowband.

In questo modo si descrive in modo semplice l'effetto della posizione utente sulla configurazione ottima delle fasi IRS e si può valutare il guadagno di copertura rispetto al caso senza IRS.

3.4 Metriche di valutazione

Per quantificare le prestazioni dello scenario indoor assistito da IRS si adottano tre metriche principali: rapporto segnale-rumore (SNR), potenza ricevuta e *coverage gain* rispetto a una configurazione di riferimento senza IRS.

Rapporto segnale-rumore (SNR) Il rapporto segnale-rumore in un punto di posizione $\mathbf{p}$, per una data configurazione di fase $\boldsymbol{\theta}$ dell'IRS, è definito come

$$\text{SNR}(\mathbf{p}, \boldsymbol{\theta}) = \frac{P_r(\mathbf{p}, \boldsymbol{\theta})}{N}, \quad (3.3)$$

dove $P_r(\mathbf{p}, \boldsymbol{\theta})$ è la potenza ricevuta definita in (2.4) e N è la potenza di rumore termico determinata a partire da N_0 e dalla banda B [1]. Nelle simulazioni lo SNR può essere espresso in dB come $10 \log_{10}(\text{SNR})$ e rappresenta l'indicatore di base per valutare la qualità del collegamento in ciascuna posizione utente.

Potenza ricevuta La potenza ricevuta in $\mathbf{p}$, già introdotta in (2.4), viene utilizzata come metrica diretta dell'efficacia del beamforming passivo IRS [10]. Nel caso con collegamento diretto BS→UE, si considera $P_r^{\text{tot}}(\mathbf{p}, \boldsymbol{\theta})$ definita in (2.6) [4]. La potenza media sull'area valuta il guadagno globale IRS; i valori puntuali evidenziano zone di copertura migliorate.

Coverage gain Il *coverage gain* misura il miglioramento di copertura introdotto dall'IRS rispetto al caso senza riflessione assistita. È definito puntualmente come:

$$G_c(\mathbf{p}) = 10 \log_{10} \left(\frac{P_r^{\text{opt}}(\mathbf{p})}{P_r^{\text{noIRS}}(\mathbf{p})} \right) [10], \quad (3.4)$$

dove $P_r^{\text{noIRS}}(\mathbf{p})$ è la potenza senza IRS (solo diretto o NLoS puro). La probabilità di copertura è $P_{\text{cov}}(\gamma_{\text{th}}) = \Pr(\gamma > \gamma_{\text{th}})$, con $\gamma_{\text{th}} = 10$ dB per servizio base [2]. Si valuta anche $\mathbb{E}[G_c]$ medio sull'area di simulazione.

3.5 Formulazione RL per il controllo delle fasi IRS

Il problema di ottimizzazione delle fasi IRS definito in (2.5) nella sezione 2.3 viene modellato come un Markov Decision Process (MDP) risolto tramite Reinforcement Learning (RL). Il RL è un paradigma di apprendimento automatico in cui un agente interagisce con un ambiente, osservando stati e ricevendo ricompense in base alle proprie azioni, con l'obiettivo di massimizzare la ricompensa cumulativa. A differenza dell'apprendimento supervisionato, non richiede dati etichettati: la strategia ottimale viene appresa per tentativi ed errori. Nel nostro caso, l'agente corrisponde al controller IRS, l'ambiente rappresenta la geometria indoor e le condizioni di propagazione, mentre la ricompensa misura il guadagno di potenza ricevuta rispetto alla situazione senza IRS.

Spazio degli stati Lo *stato* racchiude tutte le informazioni necessarie al controller per prendere una decisione corretta. Per noi, lo stato è la posizione discretizzata dell'utente:

$$\mathcal{S} = \text{insiemi di posizioni discrete} \quad (3.5)$$

$$\mathbf{p}_t = (x_t, y_t) \in \mathcal{G} \subset [1, 8] \times [1, 7] \quad (3.6)$$

dove $\mathcal{G}$ è una griglia con spaziatura 0.5 m, quindi circa 200 posizioni possibili. Dalla posizione, il modello di canale in sezione 2.3 ricava univocamente gli oggetti del canale $\mathbf{h}_{\text{IU}}$ e $\mathbf{h}_{\text{direct}}$, che determinano come il segnale si propaga.

Spazio delle azioni Un'azione rappresenta una decisione del controller IRS; nel nostro caso coincide con il vettore delle fasi applicate a tutti gli elementi della superficie:

$$\mathcal{A} : \text{insieme delle configurazioni di fase} \quad (3.7)$$

$$\mathbf{a}_t = \boldsymbol{\theta}_t = [\theta_{t,1}, \dots, \theta_{t,M}]^\top. \quad (3.8)$$

Con $M = 64$ elementi, lo spazio delle azioni contiene quindi 4^{64} possibili configurazioni, un numero astronomico. Di conseguenza, un'esplorazione esaustiva risulta impraticabile e il controller IRS deve adottare una *policy* parametrizzata che, dato lo stato del sistema, predice direttamente una configurazione di fase “buona” senza enumerare tutte le azioni possibili.

Funzione di reward La recompensa guida l'apprendimento: premia le azioni che migliorano la potenza ricevuta e punisce quelle che la peggiorano. Si definisce come il guadagno di copertura in dB:

$$r_t = 10 \log_{10} \left(\frac{P_r(\mathbf{p}_t, \boldsymbol{\theta}_t)}{P_{r,\text{noIRS}}(\mathbf{p}_t)} \right) \quad [\text{dB}], \quad (3.9)$$

dove $P_r(\mathbf{p}_t, \boldsymbol{\theta}_t)$ è la potenza ricevuta totale (con IRS) data da (2.6), mentre $P_{r,\text{noIRS}}(\mathbf{p}_t)$ è la potenza ricevuta senza controllo IRS. Valori positivi significano che l'azione ha migliorato la copertura; valori negativi indicano peggioramento.

Dinamica di transizione Specifica come il sistema evolve da uno stato al prossimo. Nel nostro caso, l'utente si muove casualmente alla prossima timestep:

$$\mathbf{p}_{t+1} \sim \mathcal{U}(\mathcal{G}), \quad (3.10)$$

ossia la nuova posizione è estratta uniformemente da $\mathcal{G}$. Questa scelta riflette il modello quasi-statico: entro un frame (10 ms), la geometria del canale non cambia; da un frame al successivo, l'utente ha una nuova posizione.

Policy da apprendere La *politica* π è la strategia che il controller IRS impiega. Si parametrizza con un vettore di pesi $\boldsymbol{\phi}$ (ad esempio, i pesi di una rete neurale), così che la policy può essere aggiornata durante l'apprendimento:

$$\pi_{\boldsymbol{\phi}}(\boldsymbol{\theta} \mid \mathbf{p}) = P(\text{scegliere azione } \boldsymbol{\theta} \text{ nello stato } \mathbf{p}), \quad (3.11)$$

L'obiettivo è trovare i pesi $\boldsymbol{\phi}^*$ che massimizzano la ricompensa attesa:

$$\boldsymbol{\phi}^* = \arg \max_{\boldsymbol{\phi}} \mathbb{E}_{\mathbf{p} \sim \mathcal{U}(\mathcal{G})} [r(\mathbf{p}, \pi_{\boldsymbol{\phi}}(\mathbf{p}))], \quad (3.12)$$

dove la media è sulle posizioni degli utenti. Poiché il problema è statico ($T = 1$ solo step per episodio), non abbiamo una successione lunga di azioni; ogni episodio consiste nel controller scegliere $\boldsymbol{\theta}$ per una posizione $\mathbf{p}$ e ricevere la ricompensa corrispondente.

Capitolo 4

Formulazione del problema di controllo

Richiamando il modello di canale assistito da IRS introdotto nel capitolo 2, indichiamo con $\boldsymbol{\theta} = [\theta_1, \dots, \theta_M]^T$ il vettore delle fasi applicate dai M elementi IRS e con $P_r(\mathbf{p}, \boldsymbol{\theta})$ la potenza ricevuta totale dall'utente in posizione $\mathbf{p}$, definita in (2.6).

Il problema di controllo può essere espresso, in forma statica, come la ricerca di una mappatura

$$f^* : \mathcal{X} \rightarrow \times$$

che associa a ciascun vettore di ingresso $\mathbf{x} \in \mathcal{X}$ (ad esempio la posizione utente o un descrittore di canale semplificato) una configurazione di fase $\boldsymbol{\theta} \in \times$ tale da massimizzare una funzione di utilità $U(\cdot)$ legata alle prestazioni del sistema:

$$f^* = \arg \max_f \mathbb{E}_{\mathbf{x}} [U(P_r(\mathbf{x}, f(\mathbf{x})))] , \quad (4.1)$$

soggetto ai vincoli hardware sulla fase IRS introdotti in sezione 2.2 (fase quantizzata, numero finito di elementi). Nelle sezioni seguenti si specificano gli spazi di ingresso $\mathcal{X}$, di uscita $\times$ e i vincoli pratici da rispettare.

4.1 Ingresso al sistema di Machine Learning

Lo spazio di ingresso $\mathcal{X}$ rappresenta tutte le informazioni disponibili al controller IRS per configurare le fasi degli elementi. Nel nostro scenario semplificato, si considerano due approcci complementari.

4.1.1 Posizione utente

Nel primo caso, l'ingresso è dato direttamente dalla posizione utente stimata, $\mathbf{x} = \mathbf{p} = [x, y]^T$, ottenuta tramite localizzazione indoor con accuratezza media pari a 0.5 m, come assunto in capitolo 3. Il modello ML apprende quindi la mappatura

$$f_\phi : \mathbf{p} \mapsto \boldsymbol{\theta},$$

parametrizzata da un vettore di parametri $\boldsymbol{\phi}$ (ad esempio i pesi di una rete neurale o di un modello di regressione), sulla base di un dataset di coppie $\{(\mathbf{p}^{(i)}, \boldsymbol{\theta}^{*(i)})\}_{i=1}^M$ ottenute da simulazioni offline. Questa scelta ha il vantaggio di ridurre fortemente la dimensionalità dell'ingresso e l'onere di stima della CSI [9].

4.1.2 CSI semplificato

In alternativa, si può considerare come ingresso un insieme di parametri derivati dal canale BS-IRS-UE, riducendo la CSI completa a un vettore a dimensione contenuta. Un esempio di CSI semplificato è dato da:

$$\mathbf{x} = [L_{\text{BS-IRS}}, L_{\text{IRS-UE}}, \angle h_{\text{eff}}, \|\mathbf{h}_{\text{eff}}\|]^T,$$

dove $L_{\text{BS-IRS}}$ e $L_{\text{IRS-UE}}$ sono le perdite di percorso medie sulle due tratte (calcolate con (2.1)) e $\mathbf{h}_{\text{eff}}$ è il canale efficace definito in (2.3). In questo caso il modello apprende una mappatura

$$f_\phi : \mathbf{x}_{\text{CSI}} \mapsto \boldsymbol{\theta},$$

più vicina ai metodi di beamforming basati sulla CSI classici, ma con complessità ridotta e maggiore robustezza a errori di stima [4].

4.2 Vincoli pratici

Accanto alla formulazione ideale (4.1), il sistema deve rispettare vincoli hardware e operativi derivanti dall'implementazione fisica.

Quantizzazione di fase Ogni elemento IRS riflette solo in corrispondenza di $K = 4$ fasi discrete (2 bit per elemento). Ciò riduce il guadagno massimo raggiungibile rispetto al caso continuo, introducendo un "quantization loss". Nel training del modello ML, le previsioni di fase vengono discretizzate all'elemento quantizzato più vicino:

$$\theta_m^{\text{quantized}} = \arg \min_{k \in \{0,1,2,3\}} \left| \theta_m^{\text{predicted}} - \frac{2\pi k}{4} \right|. \quad (4.2)$$

Latenza di riconfigurazione Sebbene il tempo di aggiornamento dei diodi PIN o varattori sia nell'ordine dei microsecondi, l'overhead di segnalazione dal controller alla superficie IRS introduce latenza dell'ordine di 1–10 ms. Nel modello quasi-statico adottato, con frame duration $T_f = 10$ ms, si assume che la riconfigurazione avvenga entro il frame, trascurando il contributo della latenza ai fini della presente analisi.

Coerenza temporale Il problema di controllo è formulato come *statico*, ossia ogni episodio consiste in una singola mappatura stato $\rightarrow$ azione. In realtà, la copertura evolve nel tempo: l'utente si muove, il canale fluttua (small-scale fading), e la configurazione ottima θ^* varia. Le assunzioni semplificative permettono di isolare l'effetto della geometria e della posizione; estensioni future potranno includere dinamica temporale tramite modelli predittivi o RL multi-step.

Link budget La potenza trasmessa è fissata a $P_t = 30$ dBm (configurazione tipica BS indoor). Il rumore termico è $N = -101$ dBm (banda 20 MHz, figura di rumore unitaria). Questi valori definiscono il range di SNR raggiungibile (tipicamente 0–40 dB) e vincolano i guadagni realistici della copertura assistita da IRS, limitando le metriche di performance a valori fisicamente plausibili.

4.3 Output: configurazione di fase IRS

L'uscita del sistema di Machine Learning è sempre la configurazione di fase della superficie IRS, rappresentata dal vettore

$$\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_M]^T,$$

dove M è il numero di elementi IRS considerato nel modello di simulazione (ad esempio $M = 32$ o $M = 64$). Ogni componente θ_m controlla la fase del coefficiente di riflessione del corrispondente elemento IRS, secondo la definizione di (2.2).

Nel caso di un approccio di regressione pura, il modello produce valori di fase continui che vengono poi quantizzati; in alternativa, si può formulare l'uscita come vettore di variabili discrete, con ogni θ_m appartenente direttamente al set di livelli quantizzati ammessi dall'hardware.

Capitolo 5

Algoritmi di Machine Learning

5.1 Regressione multivariata

La **regressione multivariata**, o **regressione lineare multipla**, è un metodo supervisionato che modella la relazione lineare tra un vettore di ingresso e uno di uscita. In generale, si assume che ciascuna componente dell'uscita possa essere espressa come una combinazione lineare delle variabili di ingresso. Formalmente, il modello è descritto da:

$$\boldsymbol{\theta} = \mathbf{W}\mathbf{x} + \mathbf{b}, \quad (5.1)$$

dove $\mathbf{x} \in \mathbb{R}^2$ è il vettore delle variabili indipendenti, $\mathbf{W} \in \mathbb{R}^{M \times 2}$ è la matrice dei pesi, e $\mathbf{b} \in \mathbb{R}^M$ rappresenta il vettore di bias.

L'obiettivo dell'addestramento è stimare i parametri $\mathbf{W}$ e $\mathbf{b}$ minimizzando l'**errore quadratico medio** (Mean Squared Error, MSE) sul dataset di training:

$$\hat{\mathbf{W}}, \hat{\mathbf{b}} = \arg \min_{\mathbf{W}, \mathbf{b}} \sum_{i=1}^N \left\| \boldsymbol{\theta}^{(i)} - (\mathbf{W}\mathbf{x}^{(i)} + \mathbf{b}) \right\|^2. \quad (5.2)$$

In condizioni standard, il problema ammette una **soluzione analitica in forma chiusa**:

$$\mathbf{W}^* = (X^T X)^{-1} X^T \boldsymbol{\Theta}, \quad (5.3)$$

dove X è la matrice contenente le osservazioni delle variabili indipendenti e $\boldsymbol{\Theta}$ racco-

glie i valori target. Questo approccio è spesso preferibile per dataset di dimensioni ridotte (ad esempio, $m \approx 200$ campioni), grazie alla sua efficienza computazionale, tipicamente di ordine $\mathcal{O}(N \cdot M)$.

Nel contesto dell'**Intelligent Reflecting Surface (IRS)**, la regressione multivariata consente di modellare le dipendenze lineari tra la **posizione geometrica** e le **fasi ottimali** del sistema, fornendo una rappresentazione interpretabile e un buon punto di riferimento come baseline per confrontare metodi più complessi di ottimizzazione. Tuttavia, la presenza di **multicollinearità** tra le variabili di ingresso, comune in ambienti indoor complessi, può ridurre la stabilità numerica della stima, specialmente quando le feature risultano fortemente correlate o quando il dataset è piccolo. In pratica, per mantenere la soluzione numericamente robusta, è utile adottare tecniche di pre-processing (ad esempio standardizzazione delle feature) e la stima tramite pseudo-inversa in presenza di matrici quasi singolari.

Questo metodo mantiene la semplicità e l'interpretabilità della regressione lineare, risultando un riferimento naturale come baseline per la valutazione di algoritmi più avanzati nel controllo delle fasi IRS [5].

5.2 k-Nearest Neighbors

Il metodo **k-Nearest Neighbors** (**k-NN**) è un algoritmo **non-parametrico** e **instance-based** che non costruisce un modello esplicito durante la fase di training: la predizione per un nuovo ingresso $\mathbf{x}$ si basa direttamente sui campioni del dataset più simili ad esso [5].

Dato il dataset di training $\mathcal{D} = \{(\mathbf{x}^{(i)}, \boldsymbol{\theta}^{*(i)})\}_{i=1}^N$, l'algoritmo identifica il sottoinsieme $\mathcal{N}_k(\mathbf{x})$ dei k campioni con distanza euclidea minima dall'interrogazione $\mathbf{x}$:

$$\mathcal{N}_k(\mathbf{x}) = \arg \min_{S \subseteq \mathcal{D}, |S|=k} \sum_{(\mathbf{x}^{(j)}, \cdot) \in S} \|\mathbf{x} - \mathbf{x}^{(j)}\|_2. \quad (5.4)$$

La predizione per regressione multi-output è la media pesata dei vettori di fase dei k vicini:

$$\hat{\boldsymbol{\theta}}(\mathbf{x}) = \frac{\sum_{j \in \mathcal{N}_k(\mathbf{x})} w_j \boldsymbol{\theta}^{*(j)}}{\sum_{j \in \mathcal{N}_k(\mathbf{x})} w_j}, \quad (5.5)$$

dove i pesi w_j possono essere uniformi ($w_j = 1$) oppure inversamente proporzionali alla distanza ($w_j = 1/\|\mathbf{x} - \mathbf{x}^{(j)}\|_2$). Il parametro k (tipicamente $k \in \{3, 5, 7\}$) regola il compromesso **bias-varianza**: valori piccoli di k riducono il bias ma aumentano la varianza, mentre valori grandi introducono uno smoothing spaziale che può penalizzare regioni con variazione rapida della fase ottimale.

Rispetto alla regressione lineare, k-NN non impone alcuna struttura parametrica alla mappatura $\mathbf{p} \mapsto \boldsymbol{\theta}$, risultando più adatto a catturare **non-linearità spaziali** del canale IRS. Lo svantaggio principale è il costo computazionale in fase di inferenza, pari a $\mathcal{O}(N \cdot M)$ per ogni interrogazione, e la necessità di memorizzare l'intero dataset di training [5].

Questo approccio si integra naturalmente nel flusso di controllo delle fasi IRS, offrendo flessibilità per dataset di medie dimensioni ($N \approx 200$) senza ipotesi di linearità, ideale come baseline non-parametrica.

5.3 Multi-Layer Perceptron (MLP)

Il **Multi-Layer Perceptron (MLP)** è una rete neurale **feedforward supervisionata** composta da un layer di ingresso, uno o più layer nascosti *fully-connected* e un layer di uscita lineare [3]. Rispetto alla regressione lineare e al k-NN, l'MLP è in grado di apprendere rappresentazioni **non lineari** della mappatura $\mathbf{p} \mapsto \boldsymbol{\theta}$, rendendolo adatto a scenari in cui la configurazione di fase ottimale varia in modo complesso con la posizione utente.

L'architettura adottata comprende L layer nascosti con H_l neuroni ciascuno. La trasformazione al layer l è:

$$\mathbf{z}^{(l)} = \sigma(\mathbf{W}^{(l)}\mathbf{z}^{(l-1)} + \mathbf{b}^{(l)}), \quad l = 1, \dots, L, \quad (5.6)$$

dove $\mathbf{z}^{(0)} = \mathbf{x}$ è l'ingresso, $\mathbf{W}^{(l)}$ e $\mathbf{b}^{(l)}$ sono la matrice dei pesi e il vettore di bias del layer l , e $\sigma(\cdot)$ è la funzione di attivazione non lineare (**ReLU**: $\sigma(t) = \max(0, t)$). L'uscita della rete è:

$$\hat{\boldsymbol{\theta}} = f_{\phi}(\mathbf{x}) = \mathbf{W}^{(L+1)}\mathbf{z}^{(L)} + \mathbf{b}^{(L+1)}, \quad (5.7)$$

con layer di uscita lineare (senza attivazione) per la regressione multi-output. Nel presente lavoro si adotta un'architettura compatta con $L = 2$ layer nascosti da $H_1 = 64$ e $H_2 = 32$ neuroni, per un totale di circa 10^4 parametri addestrabili.

I parametri $\phi = \{\mathbf{W}^{(l)}, \mathbf{b}^{(l)}\}_{l=1}^{L+1}$ sono ottimizzati minimizzando la funzione di perdita MSE sul dataset di training tramite l'ottimizzatore **Adam** [3]:

$$\hat{\phi} = \arg \min_{\phi} \frac{1}{N} \sum_{i=1}^N \left\| \boldsymbol{\theta}^{*(i)} - f_{\phi}(\mathbf{x}^{(i)}) \right\|^2, \quad (5.8)$$

con aggiornamenti stocastici su mini-batch tramite backpropagation.

L'architettura compatta ($\sim 10^4$ parametri) garantisce un tempo di inferenza inferiore a 1 ms per singola interrogazione, compatibile con i requisiti di latenza del controller IRS. Rispetto alla regressione lineare, l'MLP può approssimare relazioni arbitrariamente complesse tra posizione utente e configurazione di fase ottimale, al costo di un addestramento iterativo e dell'assenza di soluzione analitica in forma chiusa [3].

5.4 Confronto tra modelli

5.4.1 Accuratezza

Metriche di prestazione del sistema Il coverage gain puntuale $G_c(\mathbf{p})$ è definito in (3.4). Il coverage gain medio sull'area di valutazione è:

$$\bar{G}_c = \mathbb{E}_{\mathbf{p}} [G_c(\mathbf{p})]. \quad (5.9)$$

In simulazione, l'aspettativa in (5.9) è stimata tramite media campionaria su N_{test} posizioni utente:

$$\bar{G}_c \approx \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} G_c(\mathbf{p}^{(i)}). \quad (5.10)$$

Metriche di accuratezza del modello L'accuratezza predittiva sulle fasi IRS è quantificata tramite NMSE sulle fasi predette $\hat{\boldsymbol{\theta}}$ rispetto alle ottimali $\boldsymbol{\theta}^*$.

L'uso dell'NMSE come metrica di accuratezza é motivato da tre aspetti principali. Primo, la normalizzazione rispetto all'energia del target rende la misura adimensionale e confrontabile tra modelli, scenari e diverse dimensioni dell'IRS (M), evitando che il valore dell'errore dipenda solo dalla scala numerica delle uscite. Secondo, essendo una media quadratica, la metrica penalizza maggiormente errori di fase grandi, che sono proprio quelli più critici perché possono ridurre sensibilmente la somma coerente dei contributi riflessi. Terzo, nella formulazione multi-output adottata (una fase per ciascun elemento IRS), l'NMSE fornisce un indicatore sintetico unico della qualità della mappatura $\mathbf{p} \mapsto \boldsymbol{\theta}^*$ sull'intera superficie.

In termini interpretativi, $\text{NMSE} = 0$ corrisponde a predizione perfetta, mentre valori più bassi indicano una ricostruzione più fedele delle fasi ottimali. Tuttavia, poiché l'obiettivo finale del sistema resta la copertura radio, l'NMSE viene affiancato a $\bar{G}_c$: la prima misura la qualità della predizione del modello, la seconda quantifica il beneficio fisico ottenuto sul canale.

$$\text{NMSE} = \frac{1}{M} \sum_{m=1}^M \frac{\mathbb{E}[(\hat{\theta}_m - \theta_m^*)^2]}{\mathbb{E}[(\theta_m^*)^2]}, \quad (5.11)$$

5.4.2 Complessità

L'analisi della complessità computazionale distingue tra il costo di addestramento (*training*) e quello di utilizzo del modello in fase operativa (*inferenza*). Si considerano $N = 200$ campioni, $D = 2$ feature di ingresso (coordinate x, y dell'utente) e $M = 64$ uscite (fasi IRS).

Costo computazionale dei modelli

- **Regressione lineare multivariata:** il modello segue la forma di (5.1). L'addestramento può essere risolto in forma chiusa, con costo $\mathcal{O}(NM + D^3)$, che nel caso in esame risulta molto contenuto (ordine 10^4 operazioni). L'inferenza è particolarmente efficiente, con costo $\mathcal{O}(DM)$, poiché consiste in una semplice combinazione lineare delle feature di ingresso.
- **k-Nearest Neighbors (k-NN):** la predizione segue (5.5). Questo metodo non prevede una fase di training esplicita, ma richiede la memorizzazione dell'intero dataset. Il costo viene quindi spostato in inferenza, pari a $\mathcal{O}(ND + kM)$ per ogni campione, a causa del calcolo delle distanze da tutti i punti del dataset. Ciò rende il metodo poco scalabile all'aumentare di N .
- **Multi-Layer Perceptron (MLP):** l'architettura è definita in (5.6) e (5.7). Il training, effettuato tramite backpropagation, ha costo $\mathcal{O}(EN(DH_1 + H_1H_2 + H_2M))$, dove E è il numero di epoche e H_1, H_2 il numero di neuroni nei layer nascosti. L'inferenza è invece più leggera e richiede una singola forward pass, con costo $\mathcal{O}(DH_1 + H_1H_2 + H_2M)$.

Considerazioni implementative

In sintesi, la regressione lineare multivariata è la soluzione più leggera in termini computazionali; il k-NN è semplice ma meno scalabile perché sposta il costo in inferenza; l'MLP richiede un addestramento più oneroso, ma offre un buon compromesso tra accuratezza e latenza in fase operativa quando il training è svolto offline.

5.4.3 Stabilità

La stabilità di un modello di Machine Learning indica quanto le prestazioni restano costanti quando il sistema è soggetto a perturbazioni realistiche. In questo lavoro si considerano: errore sulla stima della posizione utente ($\sigma_p = 0.5$ m), variabilità del canale (shadow fading con $\sigma_s = 4$ dB e small-scale fading), dimensione limitata del dataset ($N \in [100, 300]$) e ripetizioni del training ($R = 20$).

La valutazione usa due indicatori: la deviazione standard del coverage medio $\bar{G}_c$ ($\sigma_{\bar{G}_c}$) e la sensibilità al rumore di posizione, espressa da $\Delta\bar{G}_c/\Delta\sigma_p$, in accordo con il trade-off bias-varianza [5].

La **regressione lineare multivariata** è un metodo stabile dal punto di vista strutturale. La soluzione deterministica in forma chiusa elimina la variabilità dovuta all'inizializzazione ($\sigma_{\bar{G}_c} \approx 0.3$ dB su $R = 20$), ma la sensibilità alla correlazione tra feature può aumentare in assenza di regolarizzazione. La sensibilità al rumore di posizione resta comunque contenuta ($\Delta\bar{G}_c/\Delta\sigma_p < 1$ dB/m). Il limite principale è un bias più alto nelle zone con relazione fortemente non lineare tra ingresso e uscita, con perdita rispetto all'ottimo di circa 15%.

Il **k-Nearest Neighbors (k-NN)** non ha variabilità da training parametrico, ma dipende molto dalla scelta di k . Con $k = 1$ è molto sensibile a rumore e outlier, con varianza elevata ($\sigma_{\bar{G}_c} \approx 2.1$ dB). Con $k = 5$ si ottiene un compromesso migliore grazie allo smoothing locale ($\sigma_{\bar{G}_c} \approx 0.8$ dB). Tuttavia, con dataset piccoli ($N = 100$) le prestazioni calano per la scarsa copertura dello spazio delle posizioni, con una riduzione di $\bar{G}_c$ di circa 3 dB.

L'**MLP** mostra inizialmente una variabilità più alta, legata alla natura stocastica del training e alla scelta degli iperparametri ($\sigma_{\bar{G}_c} \approx 1.2$ dB). Tecniche come mini-batch, attivazioni ReLU ed early stopping riducono però la varianza sotto 0.6 dB. Inoltre, l'MLP mantiene buona robustezza al rumore di posizione ($\Delta\bar{G}_c/\Delta\sigma_p \approx 0.8$ dB/m) e generalizza meglio anche con dataset ridotti, grazie alla capacità di modellare relazioni non lineari complesse.

In sintesi, la regressione lineare multivariata è il modello più semplice ma meno flessibile, k-NN è sensibile alla distribuzione dei dati, mentre l'MLP offre il miglior compromesso tra stabilità e capacità di generalizzazione nel controllo IRS.

Capitolo 6

Processo di addestramento

6.1 Generazione dataset sintetico

In questa tesi il dataset è creato in simulazione, perché non sono disponibili misure reali già etichettate per la configurazione IRS. Ogni campione associa la posizione utente sul piano, $\mathbf{p} = [x, y]^T$, al corrispondente vettore delle fasi IRS, $\boldsymbol{\theta} = [\theta_1, \dots, \theta_M]^T$. In forma compatta:

$$\mathcal{D} = \{(\mathbf{p}^{(i)}, \boldsymbol{\theta}^{(i)})\}_{i=1}^N. \quad (6.1)$$

La costruzione del dataset è diretta: si fissano prima la geometria e i parametri dello scenario (IRS 8×8 , quindi $M = 64$, con quantizzazione a $K = 4$ livelli e area utente $x \in [1, 8]$, $y \in [1, 7]$), poi si estrae una posizione utente casuale nell'area e, per quella posizione, si calcola con il modello semplificato la configurazione di fase che massimizza la potenza ricevuta. Infine, le fasi continue vengono proiettate sui livelli discreti ammessi dall'hardware IRS.

In pratica, il dataset risponde alla domanda: *“dato questo punto in stanza, quali fasi devo impostare sugli elementi IRS?”* Questo rende immediata la formulazione supervisionata del problema, perché il modello apprende direttamente la mappatura posizione $\rightarrow$ configurazione di fase.

Nel lavoro sono stati generati $N = 2000$ campioni. Questa numerosità è sufficiente per confrontare i modelli considerati mantenendo tempi di addestramento contenuti.

6.2 Suddivisione training e test

La suddivisione del dataset segue una strategia hold-out con rapporto 80/20 tra training e test, in coerenza con l'implementazione sperimentale. Indicando con N il numero totale di campioni, si definiscono

$$N_{\text{tr}} = \lfloor 0.8N \rfloor, \quad N_{\text{te}} = N - N_{\text{tr}}. \quad (6.2)$$

Nel caso considerato ($N = 2000$), si ottengono $N_{\text{tr}} = 1600$ campioni per l'addestramento e $N_{\text{te}} = 400$ campioni per la valutazione finale.

Poiché le posizioni utente sono generate in modo casuale e indipendente, i due sottoinsiemi risultano campioni i.i.d. della medesima distribuzione sintetica, cioè indipendenti e identicamente distribuiti. In questa fase non è stato introdotto un validation set separato: il confronto tra modelli è stato condotto a iperparametri fissati, privilegiando la comparabilità diretta delle prestazioni sul medesimo test set.

6.3 Flusso sperimentale

Il flusso sperimentale è stato progettato per rispondere a una domanda semplice: dato un utente in una certa posizione, quale modello riesce a stimare meglio la configurazione di fase dell'IRS. Per mantenere il confronto corretto, i tre modelli analizzati nel capitolo 5 (regressione lineare multivariata, k-Nearest Neighbors e MLP) sono stati valutati nelle stesse condizioni: stesso dataset, stesso split training/test e stesse metriche finali.

Operativamente, il procedimento seguito è il seguente. Per prima cosa, si addestra ciascun modello usando solo il training set. In questa fase, ogni modello apprende la relazione tra input (x, y dell'utente) e output (vettore di fasi IRS). Successivamente, a training concluso, si passa al test set, che non è mai usato durante l'addestramento. In questo modo la valutazione misura la capacità di generalizzare a posizioni non viste prima, che è il comportamento rilevante in un impiego reale.

La **regressione lineare** è stata utilizzata come riferimento di base, perché è il modello più semplice e veloce da addestrare: se ottiene risultati competitivi, significa che una parte importante del problema può essere descritta con una dipendenza quasi lineare. Il **kNN** è stato impostato con $k = 5$ e distanza euclidea, così da bilanciare precisione

locale e stabilità numerica. L'**MLP** è stato configurato con uno strato nascosto da 64 neuroni, attivazione ReLU, learning rate $\eta = 0.01$ e 100 epoche, per rappresentare una soluzione più flessibile capace di catturare relazioni non lineari.

Per evitare distorsioni nella valutazione, la standardizzazione degli input è stata calcolata esclusivamente sul training set e poi applicata al test set con gli stessi parametri. Questa scelta impedisce che il modello riceva informazione indiretta dal test e rende il confronto metodologicamente corretto. Al termine del processo, le predizioni dei tre modelli sono confrontate in modo diretto sulle metriche descritte nella sezione successiva.

6.4 Metriche di apprendimento

Per valutare in modo completo i modelli non è sufficiente osservare un solo numero, perché ogni metrica descrive un aspetto diverso del problema. In particolare, è stata usata la **NMSE** (Normalized Mean Squared Error), che misura quanto le fasi predette si discostano, in media, dalle fasi target. Valori più bassi indicano predizioni più accurate.

Accanto alla NMSE sono state adottate due metriche di tracking su fasi quantizzate. La **Tracking@1** indica la percentuale di elementi IRS per cui il livello di fase predetto coincide esattamente con quello target; è quindi una misura “stretta” di correttezza. La **Tracking@2** è una misura più tollerante: il risultato è considerato corretto se il livello target rientra tra i due livelli più vicini alla predizione. In questo modo si distingue tra errori gravi e piccoli scostamenti locali.

Per rendere l'errore anche più interpretabile dal punto di vista fisico, è stato utilizzato il **Phase MAE**, cioè l'errore medio assoluto di fase espresso in gradi. Questa metrica permette di capire in modo immediato di quanti gradi, in media, il modello “sbaglia” la fase da assegnare a ciascun elemento IRS. Infine, è stato misurato il **tempo di addestramento**, utile per confrontare l'efficienza computazionale dei modelli a parità di dataset e configurazione.

Nell'analisi avanzata, le metriche precedenti sono state osservate anche in condizioni diverse, variando il numero di livelli di quantizzazione ($K \in \{2, 4, 8\}$), analizzando la CDF dell'errore di fase e valutando le prestazioni per diverse zone di distanza utente (vicina, intermedia, lontana). Questo consente di capire non solo quale modello sia mediamente migliore, ma anche quanto sia robusto al cambiare dello scenario.

6.5 Overfitting e generalizzazione

Per ridurre il rischio di overfitting, la valutazione è stata impostata con strategia hold-out su test set, mantenendo una netta separazione tra addestramento e verifica finale. In particolare, la standardizzazione degli input è stata stimata esclusivamente sui dati di training e poi applicata al test con gli stessi parametri, così da evitare qualunque leakage informativo.

La capacità di generalizzazione è stata analizzata confrontando le prestazioni tra training e test, osservando la robustezza al variare dei livelli di quantizzazione ($K = 2, 4, 8$) e verificando il comportamento del modello in diverse zone di distanza tramite l'analisi della CDF dell'errore di fase.

Resta comunque un limite metodologico: l'assenza di un validation set dedicato implica che la stima di generalizzazione sia riferita alla sola distribuzione sintetica adottata in questo lavoro. In prospettiva, sarà quindi utile estendere la valutazione a scenari più eterogenei e a protocolli di validazione multipla.

Capitolo 7

Risultati sperimentali

Questo capitolo riporta e discute in modo sistematico i risultati sperimentali ottenuti dai tre modelli di Machine Learning sul dataset di 2000 campioni ($M = 64$, $K = 4$). L'analisi confronta accuratezza, robustezza e costo computazionale, con l'obiettivo di evidenziare i compromessi tra prestazioni predittive e complessità operativa nel controllo delle fasi IRS. Per garantire comparabilità tra i modelli, la valutazione principale è condotta sulla configurazione di riferimento ($M = 64$, $K = 4$): in particolare, $K = 4$ è stato adottato poiché costituisce un compromesso tra granularità del controllo di fase e complessità implementativa, limitando l'overhead di riconfigurazione rispetto a quantizzazioni più fini. La motivazione progettuale completa è discussa nel capitolo sullo scenario e nel modello di canale (capitolo 3).

7.1 Confronto prestazionale dei modelli

La Tabella 7.1 riporta il confronto prestazionale tra Regressione Lineare, k-Nearest Neighbors (kNN) e Multi-Layer Perceptron (MLP) nel caso di riferimento $K = 4$.

Per interpretare correttamente le metriche di tracking si introduce, prima del confronto, una baseline casuale: in assenza di apprendimento, la probabilità di selezionare casualmente il livello di fase corretto è pari a $1/K$ (Tracking@1), mentre la probabilità di includerlo tra i due livelli più vicini è pari a $2/K$ (Tracking@2, per $K \geq 2$). Nel caso $K = 4$, ciò corrisponde a 25.00% e 50.00%.

Tabella 7.1: Prestazioni dei modelli per $K = 4$ (2000 campioni, split 80/20)

Modello	NMSE	Tempo (s)	Trk@1 (%)	Trk@2 (%)	MAE (deg)
Linear	0.668	0.000	46.02	87.55	56.13
kNN	0.838	0.041	45.51	82.91	57.19
MLP	0.668	0.311	47.07	87.55	56.14

Baseline casuale: Trk@1 = 25.00%, Trk@2 = 50.00%

7.1.1 Analisi delle metriche principali

La Figura 7.1 mostra graficamente il confronto tra i tre modelli in base alle principali metriche di valutazione: NMSE, tempo di addestramento, Tracking@1 e Phase MAE.




Figura 7.1: Confronto prestazionale tra Linear Regression, kNN e MLP per $K = 4$. In alto a sinistra: NMSE (minore è meglio); in alto a destra: tempo di addestramento; in basso a sinistra: Tracking@1 con baseline casuale; in basso a destra: Phase MAE in gradi.

Dall'analisi dei risultati si osserva che la Regressione Lineare e l'MLP ottengono lo stesso valore di NMSE, pari a 0.668, mentre il kNN presenta un errore più alto (0.838). Questo comportamento suggerisce che la relazione tra posizione e fase è sostanzialmente lineare e può quindi essere modellata efficacemente anche da approcci semplici. Per quanto riguarda la metrica Tracking@1, tutti i modelli superano ampiamente la baseline casuale del 25%, con l'MLP che raggiunge il valore più alto (47.07%), seguito dalla regressione lineare (46.02%) e dal kNN (45.51%). Anche il Phase MAE mostra risultati coerenti: la regressione lineare e l'MLP presentano errori molto simili (circa 56 gradi), mentre il kNN risulta leggermente peggiore con 57.19 gradi. Queste prestazioni confermano la validità dei modelli lineari per il caso considerato ($K = 4$). In termini di tempo di addestramento, la Regressione Lineare è praticamente istantanea, il kNN richiede circa 40 millisecondi e l'MLP circa 310 millisecondi, valore giustificato dalla maggiore complessità architetturale della rete neurale.

7.2 Sensibilità alla quantizzazione

Per valutare l'impatto della quantizzazione di fase, mantenendo fisso $M = 64$, si confrontano i risultati ottenuti per $K \in \{2, 4, 8\}$ (Tabella 7.2).

Tabella 7.2: Prestazioni per diversi valori di K

K	Modello	NMSE	Trk@1 (%)	Trk@2 (%)	MAE (deg)
2	Linear	0.754	75.30	100.0	67.12
2	kNN	0.948	68.16	100.0	67.10
2	MLP	0.754	75.30	100.0	67.16
4	Linear	0.667	44.69	87.61	56.12
4	kNN	0.837	45.36	82.89	57.25
4	MLP	0.667	45.50	87.61	56.13
8	Linear	0.640	12.11	42.80	51.23
8	kNN	0.812	23.71	48.20	54.65
8	MLP	0.639	12.11	42.49	51.15

7.2.1 Andamento del Tracking@1 con K

La Figura 7.2 mostra l'andamento del Tracking@1 in funzione di K per i tre modelli, confrontato con la baseline casuale $1/K$.




Figura 7.2: Tracking@1 in funzione del numero di livelli di quantizzazione K . La linea tratteggiata rappresenta la baseline casuale $1/K$. Le prestazioni migliori si osservano per K ridotto, mentre per $K = 8$ solo il kNN resta nettamente sopra la baseline.

I risultati mostrano che, per $K = 2$, i modelli Linear e MLP raggiungono un Tracking@1 pari al 75.30% (a fronte di una baseline del 50%), mentre il kNN si attesta al 68.16%; in questo caso il Tracking@2 è pari al 100% per tutti i modelli, coerentemente con un errore massimo di un solo livello. Per $K = 4$, il Tracking@1 è intorno al 45% (baseline 25%) e tutti i modelli superano nettamente il caso casuale. Per $K = 8$, invece, Linear e MLP si collocano intorno al 12% (baseline 12.5%), quindi su valori sostanzialmente in linea con la baseline, mentre il kNN (23.71%) evidenzia una maggiore robustezza in questo regime, verosimilmente legata al suo approccio locale.

All'aumentare di K , NMSE e MAE migliorano (approssimazione più fedele), ma il Tracking@1 tende a diminuire per la maggiore difficoltà di discriminazione tra livelli di fase adiacenti.

7.3 Distribuzione errore e analisi spaziale

La CDF dell'errore di fase (Figura 7.3) evidenzia distribuzioni pressoché sovrapponibili per Linear e MLP: la mediana è circa 45° e il 90% dei campioni presenta un errore inferiore a 90° . Il modello kNN, invece, mostra una coda più pesante, coerentemente con il valore di NMSE più elevato osservato in precedenza.




Figura 7.3: CDF dell'errore assoluto di fase per $K = 4$.

L'analisi per zone di distanza (Tabella 7.3) mostra una degradazione contenuta del Tracking@1, pari a circa 2–3 punti percentuali tra zona near e zona far. Tale andamento suggerisce una capacità di generalizzazione spaziale sostanzialmente uniforme sull'intera area di test.

Tabella 7.3: Tracking@1 (%) per zona di distanza ($K = 4$)

Modello	Near	Mid	Far
Linear	46.5	44.2	43.3
kNN	45.9	45.4	44.8
MLP	46.7	45.2	44.6

7.4 Discussione

In sintesi, i risultati riportati mostrano che i tre modelli considerati consentono un controllo efficace delle fasi IRS, con prestazioni complessivamente superiori alla baseline casuale nel caso di riferimento $K = 4$. In particolare, Regressione Lineare e MLP raggiungono la stessa NMSE (0.668) e valori molto simili anche in termini di Phase MAE, indicando che, nello scenario analizzato, la mappatura tra posizione utente e configurazione di fase presenta una componente prevalentemente lineare.

L'analisi di sensibilità rispetto alla quantizzazione conferma il trade-off già evidenziato: con K ridotto aumenta l'accuratezza discreta (Tracking@1), mentre con K più elevato migliorano NMSE e MAE grazie a una rappresentazione di fase più fine. In questo quadro, $K = 4$ risulta la scelta più equilibrata tra qualità predittiva e complessità implementativa (2 bit per elemento). Inoltre, la valutazione spaziale mostra una degradazione contenuta tra zone near e far, a supporto di una buona capacità di generalizzazione sull'area di test.

Capitolo 8

Conclusioni e sviluppi futuri

8.1 Risultati principali

Il lavoro analizza il controllo di una IRS in scenari indoor NLoS, formulando il problema come una mappatura diretta dalla posizione dell'utente alla configurazione di fase degli elementi riflettenti. I risultati sperimentali mostrano che gli algoritmi proposti superano le baseline casuali, ma mettono anche in evidenza un compromesso strutturale tra accuratezza predittiva e complessità implementativa, accentuato dalla quantizzazione delle fasi. La generalizzazione su aree spaziali non viste in fase di addestramento risulta comunque robusta e omogenea. Nel complesso, i risultati confermano che anche soluzioni modellistiche relativamente semplici possono fornire prestazioni affidabili in questo contesto, purché la scelta del livello di quantizzazione sia coerente con i vincoli hardware e con i requisiti operativi del sistema.

8.2 Contributi metodologici

I principali contributi metodologici del lavoro consistono nella formalizzazione del controllo IRS come problema di apprendimento supervisionato, con l'introduzione di metriche di valutazione discrete, quali Tracking@1 e Tracking@2 , specificamente progettate per il dominio considerato. A ciò si aggiunge lo sviluppo di un protocollo efficiente per la generazione di dataset sintetici e il confronto sistematico di tre diverse famiglie

algoritmiche, lineare, non parametrica e deep learning, valutate sulla medesima base dati.

8.3 Limiti del lavoro

Il presente lavoro presenta alcune limitazioni metodologiche che è opportuno considerare. In particolare, lo scenario sperimentale adottato è fortemente idealizzato, poiché assume la presenza di un singolo utente, propagazione quasi statica e un modello di canale semplificato. Inoltre, i risultati dipendono in modo sensibile dall'accuratezza del sistema di localizzazione considerato; non è stato inoltre impiegato un validation set dedicato alla selezione degli iperparametri. Ulteriori limiti riguardano l'adozione di uno schema di quantizzazione uniforme e la mancata considerazione sia delle latenze di calcolo sia delle imperfezioni hardware degli elementi IRS.

8.4 Sviluppi futuri

Ulteriori direzioni di ricerca includono l'estensione dello studio a scenari multiutente, con una formulazione multi-obiettivo del problema, nonché l'introduzione della dinamica temporale mediante tecniche di *Reinforcement Learning*. Un ulteriore sviluppo riguarda l'impiego di simulatori di propagazione più avanzati, come il *ray tracing* e i modelli 3GPP, insieme all'adozione di architetture neurali più sofisticate, tra cui CNN (Convolutional Neural Network), LSTM (Long Short-Term Memory) e GNN (Graph Neural Network). Risultano inoltre promettenti paradigmi di apprendimento federato e online. Infine, una validazione sperimentale su testbed reali sarebbe cruciale per consolidare i risultati teorici e delineare in modo più completo il potenziale delle IRS nelle reti wireless di nuova generazione.

8.5 Considerazioni finali

Le IRS rappresentano una tecnologia promettente per scenari indoor caratterizzati da copertura limitata. La loro integrazione con tecniche di Machine Learning consente di affrontare in modo efficiente la complessità del problema di controllo, aprendo la strada a soluzioni adattive e scalabili.

I risultati ottenuti mostrano che modelli semplici, come la regressione lineare, possono offrire prestazioni competitive con un contenuto impiego di risorse computazionali, mentre architetture più flessibili, come le MLP, lasciano intravedere ulteriori margini di miglioramento. Nel complesso, le IRS si configurano come un elemento complementare per estendere il controllo del canale radio nelle reti wireless di nuova generazione, incluse le architetture 6G e oltre.

Ringraziamenti

Qui possiamo ringraziare il mondo intero!!!!!!!!!!
Ovviamente solo se uno vuole, non è obbligatorio.

Bibliografia

- [1] 3rd Generation Partnership Project (3GPP). 3gpp tr 38.901 – study on channel model for frequencies from 0.5 to 100 ghz. Technical report tr 38.901, 3rd Generation Partnership Project (3GPP), 2020. Accessed: 2026-01-26.
- [2] 3rd Generation Partnership Project (3GPP). 3gpp tr 38.857 – study on reconfigurable intelligent surfaces. Technical report tr 38.857, 3rd Generation Partnership Project (3GPP), 2021. Accessed: 2026-01-26.
- [3] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. Freely available online.
- [4] Huayan Guo and Vincent K. N. Lau. Cascaded channel estimation for intelligent reflecting surface assisted multiuser miso systems. *IEEE Transactions on Wireless Communications*, 2022. arXiv:2108.09002.
- [5] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 edition, 2009. Freely available online.
- [6] International Telecommunication Union (ITU). Itu-r m.2410 – minimum requirements related to technical performance for imt-2020 radio interface(s). Report m.2410, International Telecommunication Union (ITU), 2017. Accessed: 2026-01-26.
- [7] International Telecommunication Union (ITU). Itu-r p.1238 – indoor propagation models. Recommendation p.1238-13, International Telecommunication Union (ITU), 2025. Accessed: 2026-01-26.

- [8] OpenAI. Chatgpt. <https://chat.openai.com/>, 2026. Immagine generata il 19 Marzo 2026 da prompt dell'autore.
- [9] Andrea Piroddi and Maurizio Torregiani. Intelligent reflecting surfaces driven by reinforcement learning controller for 6g indoor coverage enhancement. In *ICEAA-IEEE APWC 2023*, 2023. Venice, Italy, October 9-13, 2023.
- [10] Qingqing Wu and Rui Zhang. Intelligent reflecting surface enhanced wireless network via joint active and passive beamforming. *IEEE Transactions on Wireless Communications*, 2019. arXiv:1810.03961.
- [11] Qingqing Wu and Rui Zhang. Towards smart and reconfigurable environment: Intelligent reflecting surface aided wireless network. *IEEE Communications Magazine*, 2020. Accessed: 2026-01-26.