



Alma Mater Studiorum – Università di Bologna

Dipartimento di Informatica - Scienza e Ingegneria

Intelligent Reflecting Surfaces

Progettazione, modellazione e ottimizzazione

Relatore

Chiar.mo Prof. Andrea Piroddi

Presentata da

Alessandro Rebosio

Contesto e Motivazione



Traffico Dati

Crescita esponenziale guidata dal 5G+.



Limiti Indoor

mmWave vulnerabili ad ostacoli fisici.



Massive MIMO

Costi e consumi energetici elevati.



Nuovo Paradigma

Controllare attivamente l'ambiente di propagazione del segnale.

Che cosa sono le IRS?



Metasuperfici

Superfici planari composte da un elevato numero di piccoli elementi riflettenti passivi.



Riconfigurabilità

Ogni elemento può introdurre uno sfasamento controllato (θ) al segnale incidente.



Efficienza

Dispositivi passivi a basso costo e basso consumo (niente catene RF attive).

Principio di Funzionamento

Le IRS manipolano il fronte d'onda per creare un collegamento virtuale **Line-of-Sight (LoS)**.



Onda Incidente

Segnale proveniente dalla Base Station (BS).




Controllo Fase

Regolazione digitale degli elementi.



Riflessione Coerente

I segnali si sommano costruttivamente all'utente.



Il Problema Affrontato



Obiettivo e Sfide

- Massimizzare la potenza ricevuta (SNR) in scenari indoor critici.
- Ottimizzazione delle fasi è un problema **non convesso**.
- Molte variabili e quantizzazione discreta (hardware reale).

Soluzione:

Utilizzare il Machine Learning per mappare

Posizione → **Fasi**.

Scenario di Simulazione



Area

Stanza 10m x 8m x 3m



Frequenza

3.5 GHz (Banda 5G)



IRS

Griglia 8x8 (64 elementi passivi)




Quantizzazione

K=4 livelli di fase (2 bit)



Dataset

2000 posizioni campionate



Ambiente modellato per riflettere un ufficio indoor realistico.

Metodologia Proposta

1. Input



Posizione Utente
 $P(x, y, 1.0)$

2. Modello ML



Apprendimento
Supervisionato

3. Predizione



Configurazione di Fase
 $\Theta(\theta)$

4. Ottimo



Max SNR e Copertura

Algoritmi a Confronto




Regressione Lineare

Vantaggio:

Estrema efficienza e semplicità computazionale.

Limite:

Difficoltà nel catturare non-linearità spaziali.



k-Nearest Neighbors

Vantaggio:

Metodo non parametrico, ottimo per relazioni locali.

Limite:

Scalabilità ridotta con dataset molto grandi.



Multi-Layer Perceptron

Vantaggio:

Alta flessibilità per modellare relazioni complesse.


Limite:

Richiede più tempo di addestramento.

Metriche di Performance

Metrica	Cosa misura?	Obiettivo
NMSE	Errore Quadratico Medio Normalizzato sulle fasi	Minimizzare
Tracking@1	Percentuale di elementi con fase predetta esatta	Massimizzare
Tracking@2	Percentuale di elementi con errore di fase entro ± 1 livello	Massimizzare
Phase MAE	Errore medio assoluto in gradi ($^{\circ}$)	Sotto i 60°
Training Time	Tempo necessario per addestrare il modello	Efficienza

Risultati: Precisione del Tracking



Messaggio Chiave

I risultati evidenziano come Linear e MLP siano quasi sovrapponibili in precisione, con quest'ultimo che richiede tuttavia tempi di addestramento significativamente superiori.

Discussione del Trade-off

Efficienza


La regressione lineare è istantanea rispetto all'MLP.

Accuratezza

I modelli superano ampiamente la baseline casuale (25%).

Quantizzazione

4 livelli offrono la stabilità necessaria per l'hardware.



K=4

OTTIMALE

Conclusioni e Sviluppi Futuri

Conclusioni Principali

-  Le IRS migliorano drasticamente la copertura indoor NLoS.
-  Il Machine Learning permette un controllo real-time efficace.
-  Modelli lineari sono validi punti di partenza.

Prospettive Future

- 01** Scenari Multi-utente (MIMO).
- 02** Reinforcement Learning per mobilità.
- 03** Validazione su prototipi hardware reali.

Grazie per l'attenzione

Alessandro Rebosio

Relatore: Prof. Andrea Piroddi

Università di Bologna